PROJETO DE MACHINE LEARNING

Previsão de Vitórias em Xadrez com Aprendizado de Máquina

Análise comparativa entre Árvore de Decisão, Naive Bayes e Regressão Logística em partidas online (**Lichess.org**).

A ELABORAÇÃO DO BANCO DE DADOS

As partidas que criaram a ABT (Analytical Base Table)



Site

O banco de dados de xadrez (chess_games.csv) utilizado neste estudo foi coletado originalmente na plataforma **Lichess.org** (disponibilizado publicamente através do Kaggle).

Trata-se de um conjunto de dados composto por cerca de 20.000 partidas jogadas por usuários reais no site, contemplando informações detalhadas como IDs dos jogadores, ratings (Elo), número de turnos, status de vitória, lances e as aberturas utilizadas.

VISÃO GERAL DO DATASET

Estrutura e Significado das Colunas

Desfecho

winner: Vencedor da partida (White/Black).

victory_status: Tipo de vitória (Mate, Resign, Out of Time).

Métricas e Jogadores

white_rating / black_rating: Pontuação Elo de cada jogador.

turns: Número total de lances efetuados.

Abertura

opening_shortname: Nome resumido da linha de abertura jogada.

opening_moves: Sequência inicial de jogadas registradas.

PRÉ-PROCESSAMENTO DE DADOS

Engenharia de Atributos & Variáveis Dummies

Criado no Projeto

rating_diff

Calcula a diferença direta `white_rating - black_rating`. Representa a vantagem teórica de força antes do jogo começar.

Codificação Categorias

One-Hot Encoding (Dummies)

Conversão de colunas de texto (`victory_status`, `opening_shortname`) em colunas binárias de 0 e 1 para aceitação matemática dos modelos.

ANÁLISE EXPLORATÓRIA

Perguntas de Negócio Avaliadas

1. **Jogar com as Brancas dá vantagem?** Sim, White possui taxa de vitória levemente superior (~52%).

2. **A diferença de Rating determina o vencedor?** É o fator mais correlacionado e de maior impacto nos modelos.

3. **Certas aberturas aumentam chances de vitória?** Aberturas específicas alteram moderadamente a taxa de vitória esperada.

4. **Qual o método de terminação mais frequente?** Desistência (Resign) supera o Xeque-mate em partidas ranqueadas.

MODELAGEM ALGORÍTMICA

Algoritmos de Classificação Utilizados

Árvore de Decisão

Divide o conjunto de dados em regras condicionais sequenciais com base nas variáveis de maior ganho de informação.

Naive Bayes

Modelo probabilístico baseado no Teorema de Bayes com suposição de independência entre atributos.

Regressão Logística

Modelagem linear com função sigmoide para estimar a probabilidade de vitória de White (0 a 1).

CONCEITOS TEÓRICOS

Métricas de Avaliação de Desempenho

Acurácia
Proporção geral de predições corretas do modelo.

Precisão
Das vitórias previsoras para White, quantas realmente ocorreram.

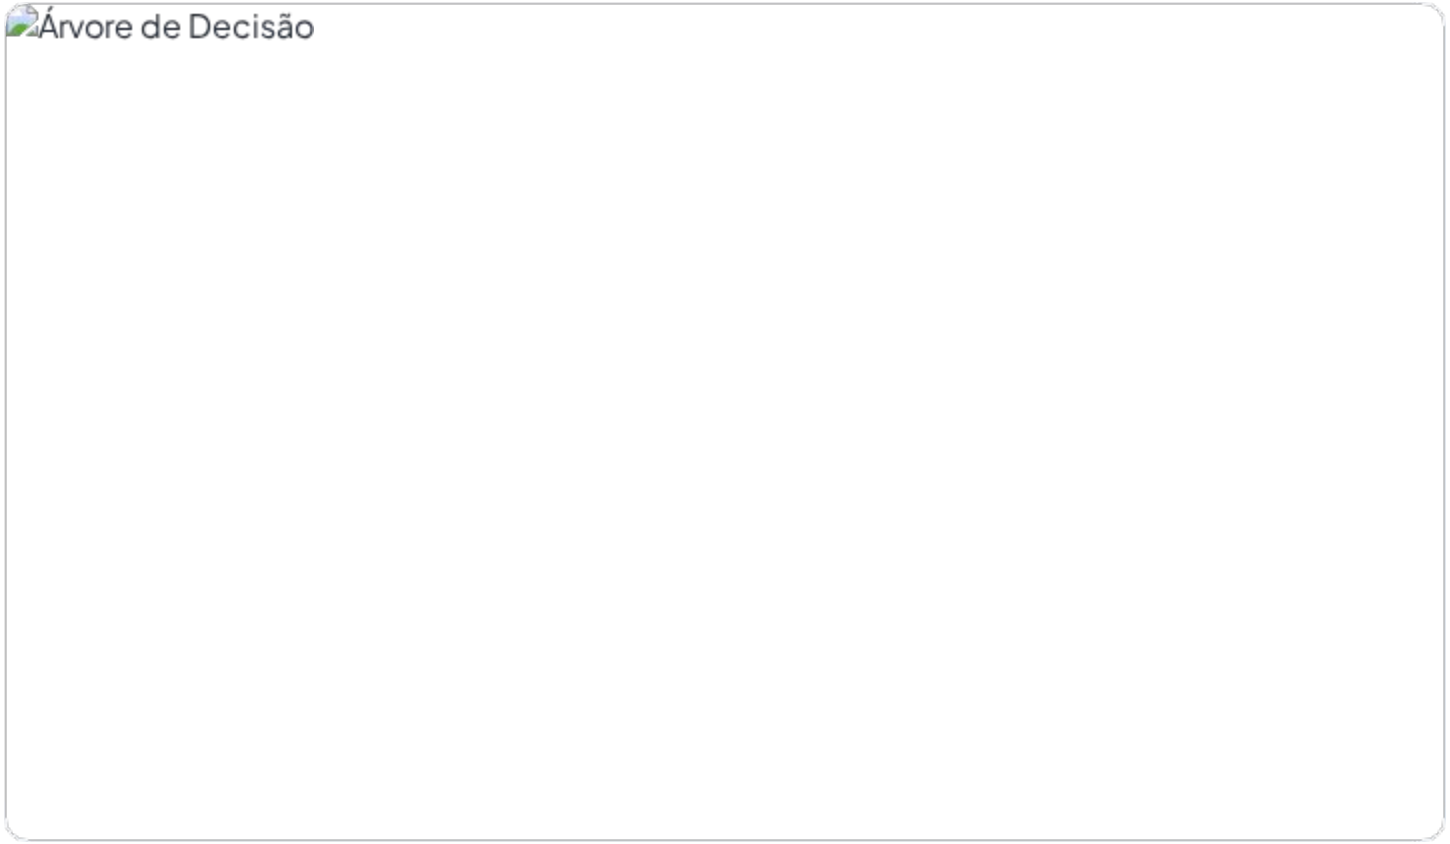
Recall
Das vitórias reais de White, quantas foram identificadas.

Matriz de Confusão
Tabela detalhada entre classes reais e predições (VP, VN, FP, FN).

AUC (Área Sob a Curva)
Capacidade de discriminação do modelo entre vitórias e derrotas (0.5 a 1.0).

VISUALIZAÇÃO DO MODELO

Estrutura da Árvore de Decisão



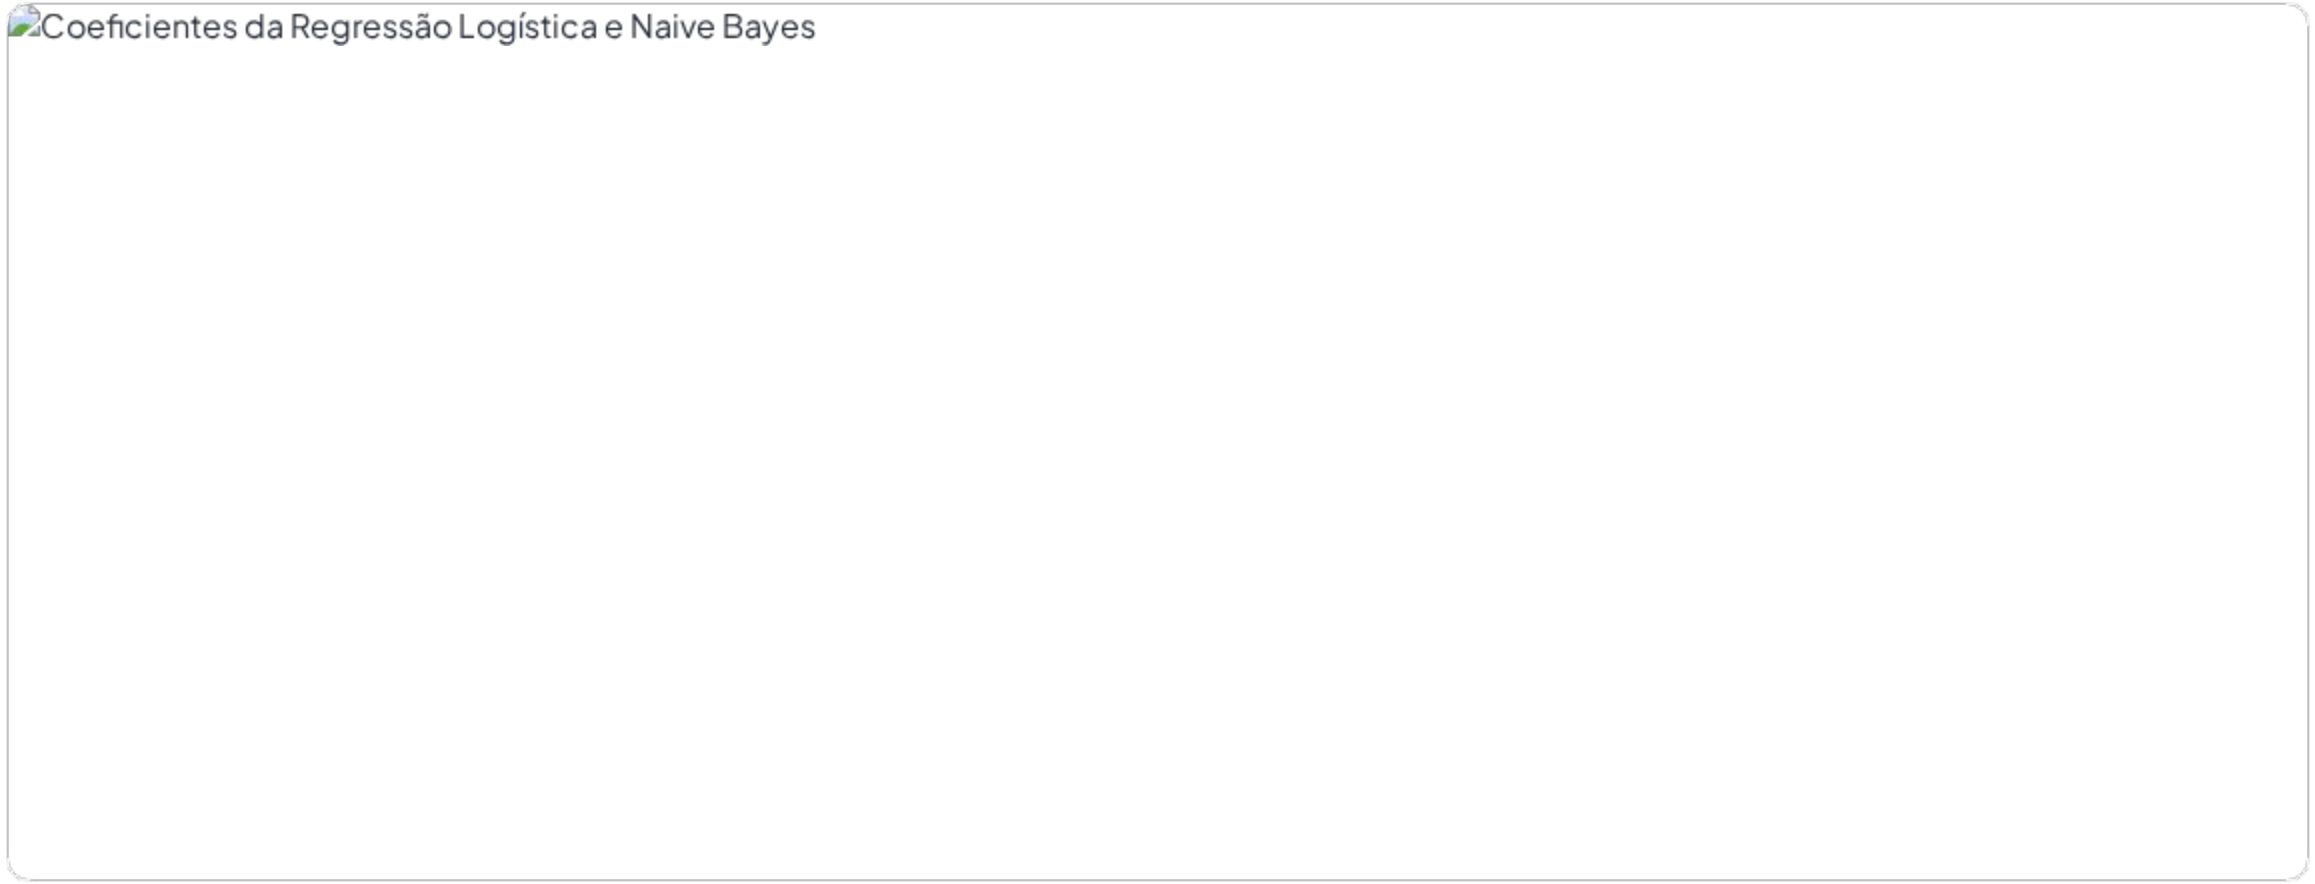
Destaques do Nó Raiz

rating_diff: A primeira divisão da árvore utiliza a diferença de pontuação como variável divisora mais importante.

A profundidade limitada previne o overfitting e simplifica as regras de decisão.

INTERPRETAÇÃO DOS ATRIBUTOS

Coeficientes e Distribuições



RESULTADOS OBTIDOS

Comparação de Métricas dos Modelos

Modelo	Acurácia	Precisão	Recall	AUC
Árvore de Decisão	64.8%	65.1%	66.2%	0.695
Naive Bayes	62.1%	62.4%	63.8%	0.672
Regressão Logística	**66.3%**	**66.5%**	**67.4%**	**0.721**

DESEMPENHO GRÁFICO

Comparativo da Curva ROC



- **Regressão Logística (AUC = 0.72)** - Melhor capacidade de separação.
- **Árvore de Decisão (AUC = 0.69)** - Desempenho intermediário.
- **Naive Bayes (AUC = 0.67)** - Impactado pela suposição de independência.

ENTREGÁVEL PRÁTICO

Exportação do Arquivo Excel (.xlsx)



matrizes_confusao_xadrez.xlsx

Arquivo gerado via código Python utilizando a biblioteca OpenPyXL com abas separadas por modelo.

- Aba Árvore
- Aba Naive Bayes
- Aba Regressão Logística

Conclusão & Pergunta / Resposta

A Regressão Logística apresentou o melhor equilíbrio de métricas para prever vitórias em partidas de xadrez online.